SVEUČILIŠTE U ZAGREBU

PRIRODOSLOVNO–MATEMATIČKI FAKULTET

MATEMATIČKI ODSJEK

Anto Čabraja

PARALELNI ALGORITMI ZA PROBLEM GRUPIRANJA PODATAKA

Diplomski rad

Voditelj rada:
prof. dr. sc. Goranka Nogo

Zagreb, srpanj 2014.

Ovaj diplomski rad obranjen je dana ____________________ pred ispitnim povjerenstvom u sastavu:

1. ____________________________, predsjednik
2. ____________________________, član
3. ____________________________, član

Povjerenstvo je rad ocijenilo ocjenom _______________.

Potpisi članova povjerenstva:

1. ____________________________
2. ____________________________
3. ____________________________

Sadržaj

Uvod

0.1 Problem grupiranja podataka

0.2 Primjena

0.3 Pregled rada

Poglavlje 1

Modeliranje problema grupiranja

1.1 Osnovni pojmovi

Kako bi u daljnjem razmatranju bilo jednostavnije objašnjavati strukture i same implementacije algoritama potrebno je problem grupiranja reprezentirati osnovnim pojmovima. U nastavku ćemo formalno definirati sve komponente od kojih se problem grupiranja sastoji.

Definicija 1.1.1. ***Uzorak*** *je apstraktna struktura podataka koja reprezentira stvarne podatke s kojima raspolaže algoritam za grupiranje.*

Definicija 1.1.2. ***Svojstvo*** *je vrijednost ili struktura koja predstavlja jednu značajku danog podatka unutar uzorka.*

Definicija 1.1.3. ***Udaljenost*** *između uzoraka definiramo kao funkciju $f : D- > \mathbb{R}$, gdje je D skup svojstava danih uzoraka*

Definicija 1.1.4. *Za uzorke kažemo da su* ***blizu*** *jedan drugome ako je njihova udaljenost manja od unaprijed zadane veličine*

Definicija 1.1.5. ***Klaster*** *je skup uzoraka koji su u prostoru podataka blizu. Ako su uzorci identični onda je njihova udaljenost uvijek* 0

Definicija 1.1.6. ***Jednistveno grupiranje*** *je postupak grupiranja kada svaki uzorak pripada jednom i samo jednom klasteru.*

Definicija 1.1.7. ***Nejasno ili nejedinstveno grupiranje*** *je postupak grupiranja gdje jedan uzorak može biti u više klastera.*

Napomena 1.1.8. *U radu ćemo promatrati* ***jedinstveno grupiranje*** *tako da će sve daljnje definicije i modeliranja predpostavljati da želimo dobiti disjunktne klastere. Jedinstveno grupiranje (eng: hard clustering) je ujedno i teži problem.*

1.2 Matematičko modeliranje problema

Definicija grupiranja podataka nije jedinstvena. U literati se na različite načine pokušava opisati ovaj postupak. Neki od pokušaja opisne definicije su:

1. *Grupiranje podataka je postupak otkrivanja homogenih*[1] *grupa uzoraka unutar skupa svih danih uzoraka.*

2. *Grupiranje podataka je postupak određivanja koji su uzorci slični te ih svrstati u isti klaster.*

Za modelirali problem neće nam biti dovoljne opisne definicije. U ovom slučaju opisne definicje mogu poslužiti samo kao intuicija o čemu se zapravo radi kada govorimo o grupiranju. U nastavku ćemo pomoću definiranih pojmova u poglavlju 1.1 matematički opisati problem grupiranja podataka.

Neka je $\mathbf{U} = \{U_1, U_2, \cdots, U_n\}$ skup od n uzoraka,te neka je $U_i = (s_1, s_2, \cdots, s_d)$ reprezentiran d-dimenzionalnim vektorom gdje s_i predstavlja jedno svojstvo. Ovako definiran $\mathbf{U}$ moguće je reprezentirati kao matricu $\mathbf{S}_{d\times n}$.Svaki stupac te matrice predstavlja jedan uzorak iz danog skupa $\mathbf{U}$.

$$\mathbf{S}_{d\times n} = \begin{pmatrix} s_{1,1} & s_{1,2} & \cdots & \cdots & s_{1,n} \\ s_{2,1} & s_{2,2} & \cdots & \cdots & s_{2,n} \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ s_{d,1} & s_{d,2} & \cdots & \cdots & s_{d,n} \end{pmatrix} \tag{1.1}$$

Iz definicje 1.1.6 te iz navedenog formalnog zapisa dajemo formalnu definiciju problema grupiranja.

Definicija 1.2.1. ***Skup od k klastera*** $\mathbf{C} = \{C_1, C_2, ..., C_k\}$ *je skup sa sljedećim svojstvima:*

- $C_i \neq \Phi$
- $C_i \cap C_j = \Phi$, $\forall i, j\ i \neq j$
- $\cup_{i=1}^{k} C_i = \mathbf{U}$

Napomena 1.2.2. *U terminima matrice* $\mathbf{Z}$ *to znači da se svaki* C_i *zapravo sastoji od stupaca matrice* $\mathbf{Z}$.

Definicija 1.2.3. ***Problem grupiranja*** *u skup od k klastera* $\mathbf{C}$ *je ekvivalentan problemu da* $\forall c, c' \in C_i$ *udaljenost od c do c′ je manja od udaljenosti c do bilo kojeg drugog* $c'' \in C_j$ $j \neq i$

[1]podaci koji se ne mogu smisleno separirati

Zapravo problem grupiranja je pronalazak najpogodnije particije za **C** u skupu svih mogućih particija. Prema napomeni 1.2.2 to znači da se zapravo radi o problemu raspodjele n stupaca matrice **Z** u k skupova

1.3 Metode razvoja algoritama za grupiranje

1.4 Upravljanje podacima

Poglavlje 2

Meta-heuristički pristup problemu

2.1 Prirodom inspirirani algoritmi

2.2 Reprezentacija podataka

2.3 Analiza rezultata

Poglavlje 3

Poznati algoritmi i analiza

3.1 Alg 1

3.2 Alg 2

3.3 Alg 3

Poglavlje 4

Tehnike za paralelizaciju algoritama

4.1 Osnovni pojmovi MPI tehnologije

4.2 Topologije

4.3 Prednosti paralelizacije i cijena komunikacije

Poglavlje 5

Konstrukcija paralelnih heurističkih algoritama za grupiranje

5.1 Algoritam 1

Opis

Analiza

5.2 Algoritam 2

Opis

Analiza

5.3 Algoritam 3

Opis

Analiza

Poglavlje 6

Ostale moderne metode

6.1 Programiranje na grafičkim karticama

6.2 MapReduce metoda

Bibliografija

[1] I. Autor, *Naslov Knjige*, Samizdat, 2052.

[2] D. E. Dutkay, D. Han, Q. Sun i E. Weber, *Hearing the Hausdorff dimension*, (2009), `http://arxiv.org/abs/0910.5433`.

[3] S. Kurepa, *Convex functions*, Glasnik Mat.-Fiz. Astr. Ser. II **11** (1956), br. 2, 89–93.

[4] ______, *Funkcionalna analiza*, Školska Knjiga, 1981.

Sažetak

Ukratko ...

Summary

In this ...

Životopis

Na slici 1.1.7 se nalazi 3D graf neke funkcije.

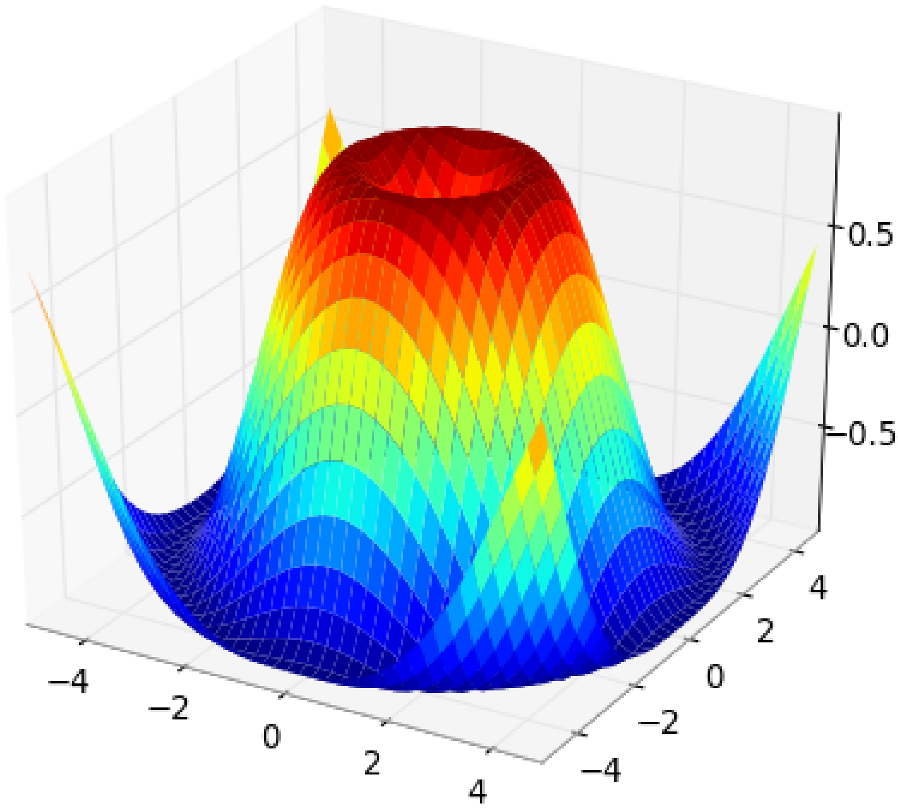

Slika 6.1: Druga slika

kao i jedna vrlo komplicirana formula koja slijedi iz (**??**)

$$\sum_{i=1}^{\infty} A_{x_1} \times A_{\alpha_2} \oslash \iint_{\Omega} x^2 \ddagger \limsup_{n \in \mathbb{N}} \frac{\alpha + \theta + \gamma}{n^{\omega}} \quad \text{je u stvari} \quad \biguplus_{r \in \mathbb{Q}} \overline{\Xi_i \underset{\substack{j \in \mathbb{C} \\ j \ni i\mathbb{Q}}}{\Theta} \Upsilon^{k^j} \underset{*}{\Psi} \hbar|_{\{\alpha\}}}.$$